Федеральное государственное образовательное бюджетное учреждение высшего образования

«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ РОССИЙСКОЙ ФЕДЕРАЦИИ»
(Финансовый университет)

Институт развития профессиональных компетенций и квалификаций

ИТОГОВАЯ РАБОТА

Название программы	**«Аналитик данных»**
Группа обучения	**«AD | 14 | 01.10.2026»**
Срок обучения	**«01.10.2026-26.11.2026»**
«Кобзев Иван Алексеевич»	
Название Датасета	**«Retail Sales Dataset»**

Москва 2026 г.

I. Описание кейса

В целях анализа данных был выбран датасет «**Retail Sales Dataset**» (https://www.kaggle.com/datasets/danielsowah123/retail-sales-dataset) мультиканальной розничной и B2B-продажи офисной техники, электроники, мебели, бытовой техники и офисных принадлежностей. Датасет состоит из двух файлов:

– Sales_transactions_2022_2025. csv: охватывает 2022-2025 годы и содержит 18.045 сырых неочищенных транзакций и 36 колонок;

Sales_transactions_2022_2025.csv	
transaction_id	Уникальный идентификатор отдельной транзакции
order_id	Идентификатор заказа
customer_id	Уникальный идентификатор клиента
customer_name	Имя клиента
customer_age	Возраст клиента в годах
customer_gender	Пол клиента
customer_segment	Сегмент клиента
order_date	Дата оформления заказа
order_time	Время оформления заказа
sales_channel	Канал продажи
store_id	Идентификатор магазина
store_name	Название магазина
country	Страна, в которой совершена продажа
region	Регион
city	Город
product_id	Уникальный идентификатор товара
product_name	Название товара
product_category	Основная категория товара
product_subcategory	Подкатегория товара
quantity	Количество единиц товара в транзакции
unit_price	Цена одной единицы товара
discount_percentage	Размер скидки в процентах
sales_amount	Сумма продажи или выручка по транзакции
cost_amount	Себестоимость проданного товара
profit	Прибыль по транзакции (sales_amount – cost_amount)
payment_method	Способ оплаты
order_status	Статус заказа
shipping_method	Способ доставки
delivery_days	Количество дней доставки

return_flag	Признак возврата
return_reason	Причина возврата
sales_representative	Менеджер по продажам, оформивший сделку
promotion_code	Промокод или код акции
customer_rating	Оценка клиента
inventory_level	Уровень складского запаса товара на момент продажи
order_year	Год оформления заказа

order_id не уникален глобально, используется составной ключ.

– sales_data_dictionary.csv: словарь-справочник, описывающий каждую колонку основного датасета.

sales_data_dictionary.csv	
column_name	Название колонки в основном датасете
description	Краткое техническое описание колонки
data_type	Тип данных
example_value	Пример значения из данных
business_meaning	Бизнес-смысл показателя

II. Цели и задачи

Руководство компании, осуществляющей розничные и корпоративные продажи электроники, мебели, бытовой техники и офисных принадлежностей через несколько каналов продаж, заинтересовано в оценке результатов деятельности за 2022–2025 годы.

Необходимо определить, какие товары, категории, регионы и каналы продаж формируют основной объём выручки и прибыли, а также выявить направления для развития бизнеса на основе данных.

На основании полученных результатов необходимо выполнить RFM-сегментацию клиентов и ABC-XYZ-анализ товаров, разработать интерактивный BI-дашборд и сформулировать рекомендации по управлению ассортиментом, планированию промоакций и работе с различными клиентскими сегментами.

В качестве основного инструмента обработки и анализа данных использовался язык программирования Python. Для выполнения операций над табличными данными применялась библиотека Pandas, для числовых вычислений — NumPy, для визуализации результатов — Matplotlib, Seaborn, Yandex DataLens.

Ссылка на GitHub с проектом: https://github.com/CASEYNGER/final_work_fa
Ссылка на Yandex DataLens: https://datalens.yandex/2dkc84cx7e3ul?_share_link=public

ЭТАП 1. ETL И ПРЕДОБРАБОТКА (PYTHON)

1.1. Загрузка и предварительный аудит данных

(основано на ноутбуке 01_etl_and_preprocessing.ipynb)

```
[10] 374ms
Файл: /Users/caseynger/DE/final_work_fa/Sales_transactions_2022_2025.csv
Размер исходных данных: 18,045 строк × 36 столбцов
Полные дубликаты: 45
Дубли Transaction_ID: 45
```

На первом этапе данные загружаются, проводится первичный аудит. Выявлено:

- **45 полных дубликатов** – удалены;
- **8 строк с** quantity ≤ 0 – сохранены в отдельный файл quantity_anomalies.csv для аудита, исключены из аналитического набора;
- **231 строка с отрицательной прибылью** – не удаляется (могут быть реальными убыточными продажами);
- Пропуски в customer_age (218), customer_racing (3 435), return_reason (16 168) – сохраняются без импутации.

После очистки аналитический набор содержит **17 992 строки**.

```
# Audit key uniqueness: retain rows, report collisions for investigation.
transaction_id_duplicates = transactions_copy[transactions_copy.duplicated('transaction_id', keep=False)].sort_values('transaction_id')
print(f'Строк с повторяющимся transaction_id: {len(transaction_id_duplicates):,}')
print('Статусы:', transactions_copy['order_status'].value_counts(dropna=False).to_dict())
print('Каналы:', transactions_copy['sales_channel'].value_counts(dropna=False).to_dict())

[11] 225ms
Удалено полных дубликатов: 45
Строк с повторяющимся transaction_id: 0
Статусы: {'completed': 11536, 'shipped': 2554, 'returned': 1597, 'processing': 1420, 'cancelled': 893}
Каналы: {'Online': 8195, 'Retail Store': 6221, 'B2B Portal': 2124, 'Phone Order': 1460}
```

1.2. Бизнес-правила и флаги

Ключевое аналитическое допущение: реализованная продажа определяется как строка со статусом completed и return_flag ≠ yes. Это не финансовое правило признания выручки из словаря, а явное допущение для воспроизводимости.

На основе этого правила формируются:

- is_realized – флаг реализованной продажи (11 349 строк);
- net_sales – выручка только по реализованным продажам ($5 175 010,17);
- net_profit – прибыль только по реализованным продажам ($1 040 355,97);
- is_b2b_channel, is_bulk_order_line, is_loss – дополнительные бизнес-флаги.

```
# Фактический B2B-канал и крупная партия — два разных понятия.
df['is_b2b_channel'] = df['sales_channel'].str.lower().eq('b2b portal').astype('int8')
bulk_threshold = df['quantity'].quantile(0.95)
df['is_bulk_order_line'] = df['quantity'].ge(bulk_threshold).astype('int8')
```

```python
# Аналитическое допущение (не прямое правило из словаря):
# в realized sales включаем только Completed и не возвращённые строки.
# Словарь описывает Order_Status как operational status, но не задаёт момент признания выручки.
REALIZED_STATUSES = {'completed'}
df['is_realized'] = (
    df['order_status'].isin(REALIZED_STATUSES)
    & df['is_returned'].eq(0)
).astype('int8')

# Sales_Amount уже описан в словаре как recorded net sales amount:
# не пересчитываем его повторно из Quantity * Unit_Price * Discount.
# Profit также берём как recorded transaction profit, не заменяем на Sales_Amount - Cost_Amount.
df['recorded_sales_amount'] = df['sales_amount']
df['net_sales'] = df['sales_amount'].where(df['is_realized'].eq(1), 0.0)
df['net_profit'] = df['profit'].where(df['is_realized'].eq(1), 0.0)
```

1.3. RFM-анализ

RFM строится только по реализованным покупкам (4 243 клиента из 4 882). Метрики:

- **Recency** – дни с последней покупки (относительно 2026-01-01);
- **Frequency** – количество уникальных заказов;
- **Monetary** – сумма `net_sales`.

```
Reference date: 2026-01-01
RFM customers: 4,243
segment
Loyal          1231
Hibernating     866
Champions       772
At Risk         427
Lost VIPs       406
New             299
Other           209
Big Spenders     33
```

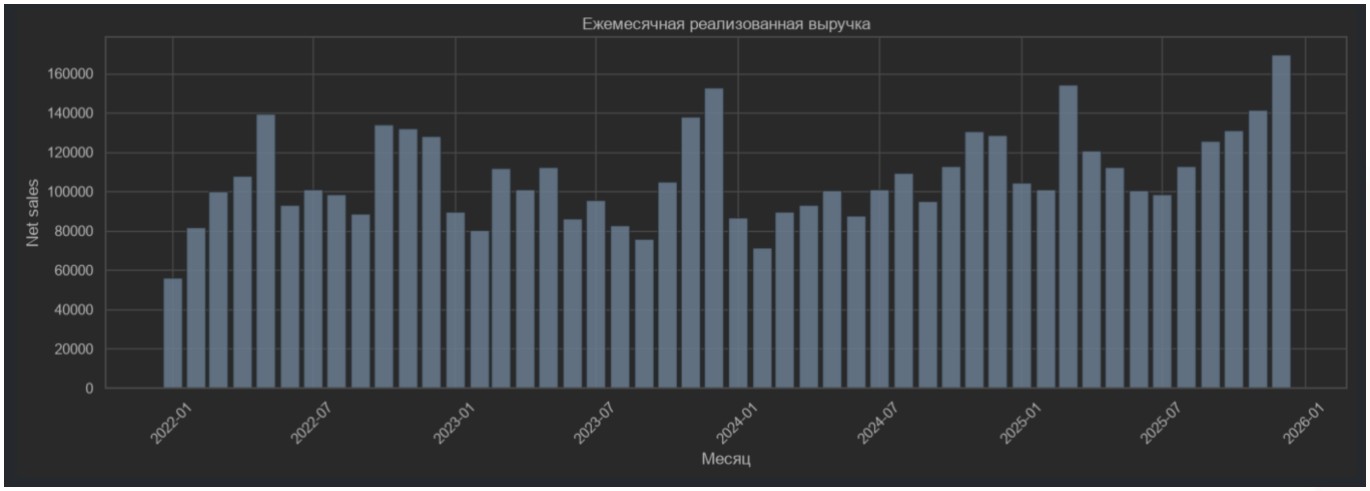
ЭТАП 2. EDA И ABC/XYZ-АНАЛИЗ (PYTHON)

2.1. Динамика продаж

Годовая динамика реализованной выручки показывает **устойчивый рост**:

Год	Net Sales ($)	Ср. мес. ($)
2022	1 261 521	105 127
2023	1 232 385	102 699
2024	1 207 418	100 618
2025	1 473 687	122 807

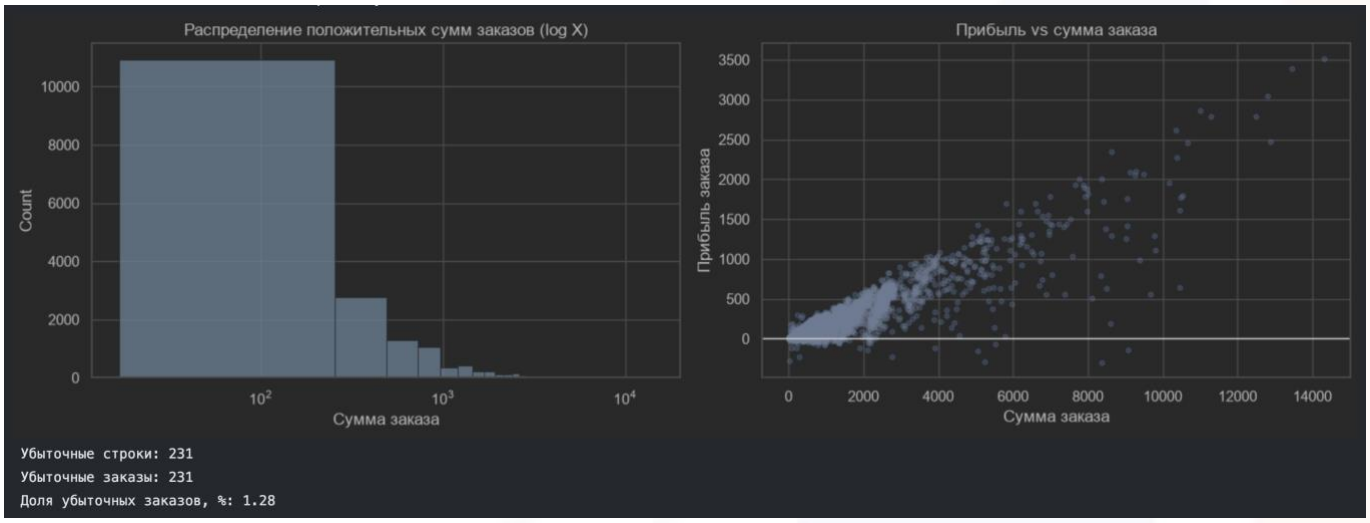
Рост 2025 к 2022: **+17%**.



Наряду с этим наблюдается сезонность продаж: в зимние периоды (до января) реализованная выручка повышается ввиду проведения промоакций, а в летние периоды понижается.

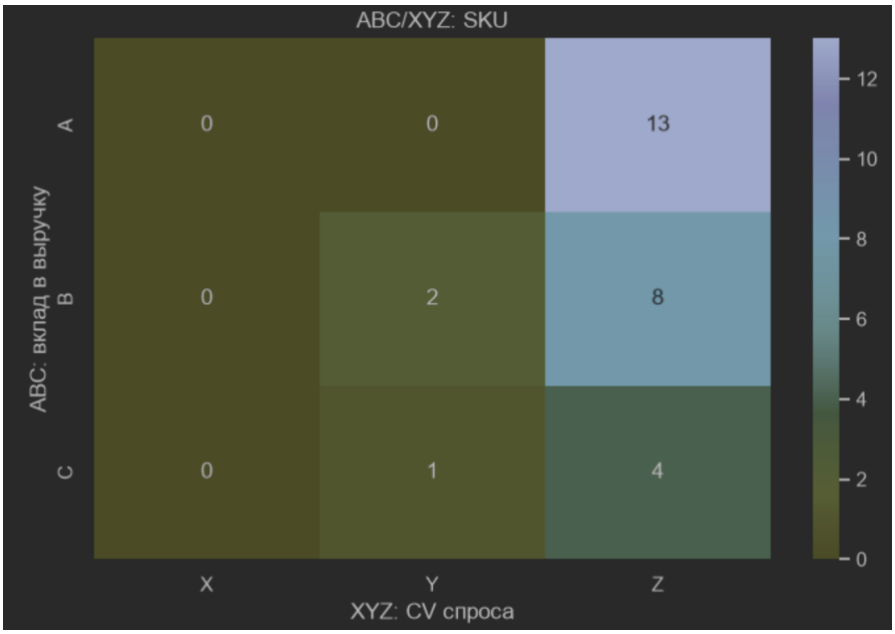
2.2. Распределение чеков и убыточность

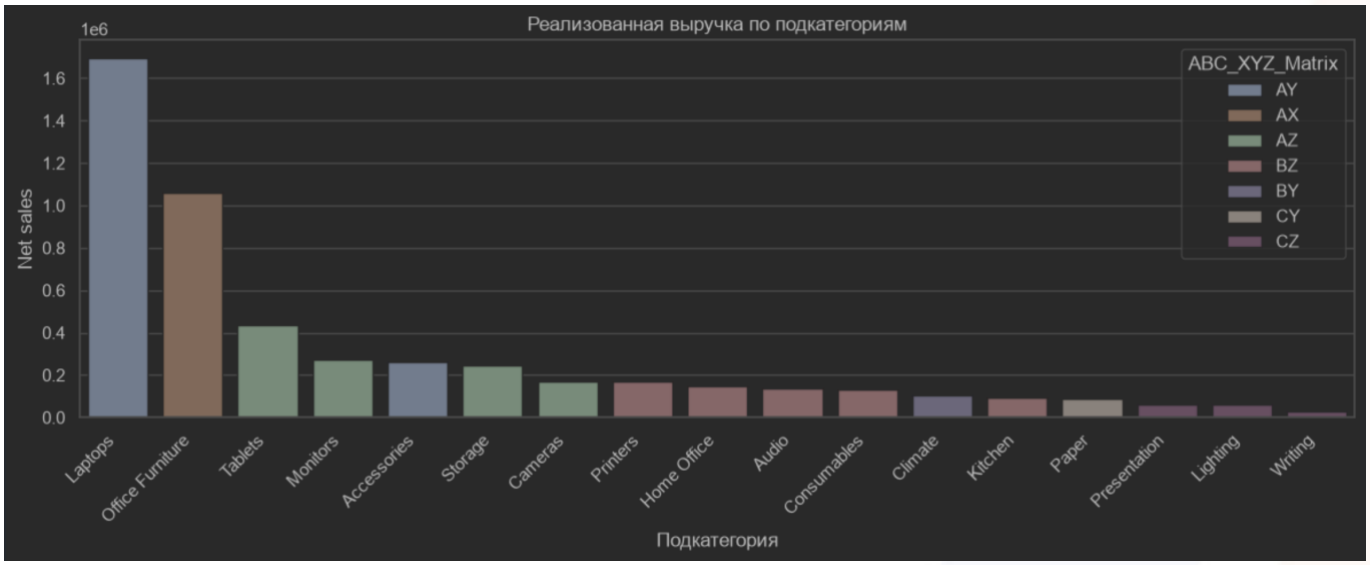
- Убыточных строк: 231 (1,28% заказов);
- B2B Portal показывает самый высокий средний чек ($1 001), но маржа та же (около 20%);
- Bulk-заказы (`qty` ≥ 95-й перцентиль): 925 строк, 20% выручки, маржа 20,1%.



2.3. ABC/XYZ-анализ

ABC классифицирует объекты по вкладу в выручку (A=80%, B=95%, C=остаток). **XYZ** – по коэффициенту вариации месячных продаж (X ≤ 0,3, Y ≤ 0,4, Z > 0,4).





Ключевой инсайт: все 13 товаров группы «A» (80% выручки) попали в группу «Z» (нестабильный спрос). Это создает риски дефицита/излишков и требует увеличения страхового запаса.

2.4. RFM x ABC

Кросс-анализ показывает, что сегмент **Champions** (772 клиента) состоит преимущественно из клиентов группы «A» (715 из 772) и генерирует $2 257 843 (44% всей выручки). Сегмент **Loyal** (1 231 клиент) дает еще 28% выручки.

```
RFM segment summary:
             clients  median_recency  avg_frequency  total_net_sales
segment
Champions        772            81.5           5.24       2257843.04
Loyal           1231           247.0           3.08       1447481.30
Lost VIPs        406           700.0           2.65        861077.16
Hibernating      866           945.0           1.00        202153.12
At Risk          427           723.0           2.41        172637.93
New              299            92.0           1.00        118088.57
Big Spenders      33           337.0           1.00         64258.14
Other            209           367.0           1.00         51470.91
```

ЭТАП 3. BI-ДАШБОРД (YANDEX DATALENS)

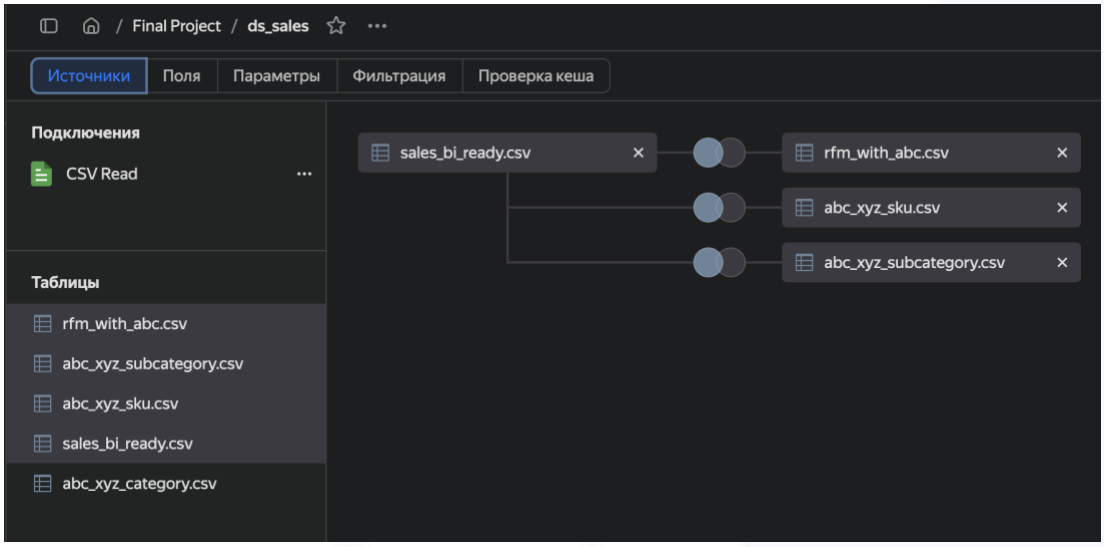
3.1. Архитектура данных

В DataLens загружается один датасет ds_sales на базе sales_bi_ready.csv (17 992 строки) с тремя LEFT JOIN:

- rfm_with_abc.csv по customer_id – RFM-сегменты и ABC клиентов;
- abc_xyz_sku.csv по product_id – ABC/XYZ группировки SKU;
- abc_xyz_subcategory.csv по product_subcategory – ABC/XYZ подкатегорий.

Ключевые вычисляемые поля:

- Realized Orders = COUNTD(IF [is_realized]=1 THEN [customer_order_key] END);
- Net Margin = SUM(net_profit) / SUM(net_sales);
- AOV = SUM(net_sales) / [Realized Orders];
- Segment BI = IFNULL([segment], "No realized purchases").



3.2. Executive Summary (обзор)

Вкладка содержит четыре KPI-индикатора и четыре графика.



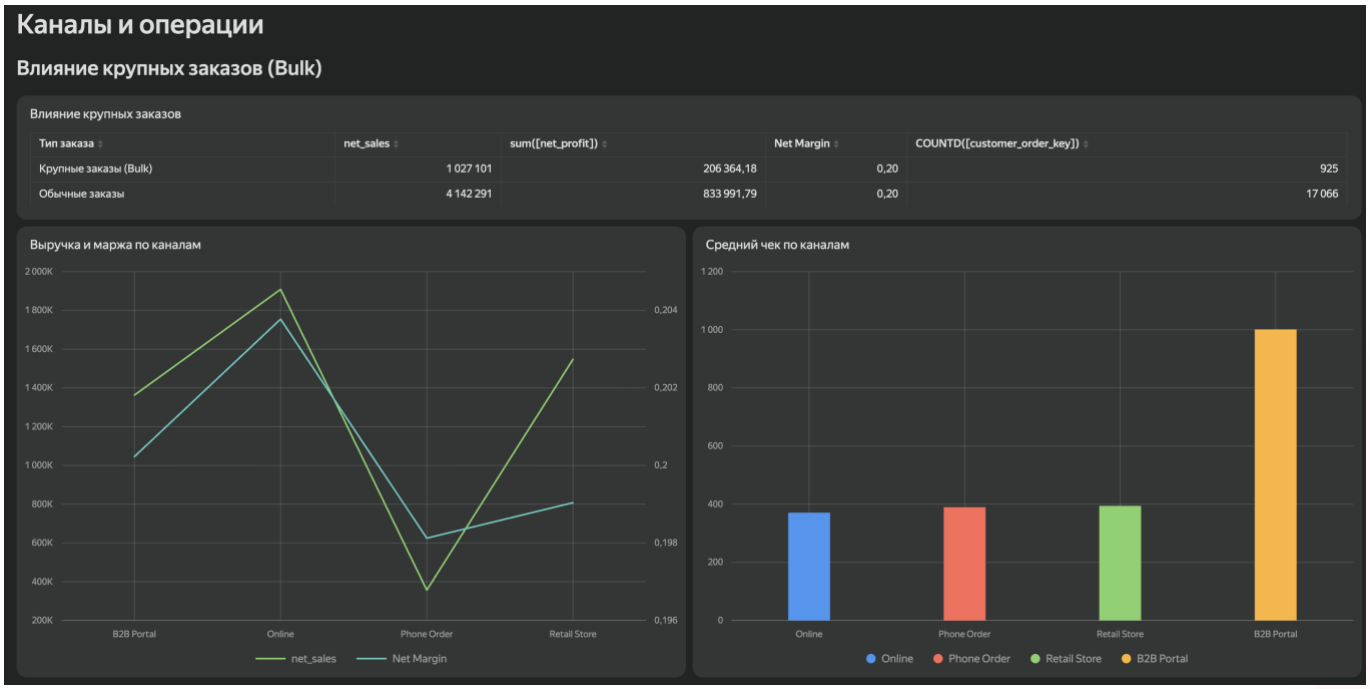


3.3. Каналы и операции

Анализ каналов показывает:

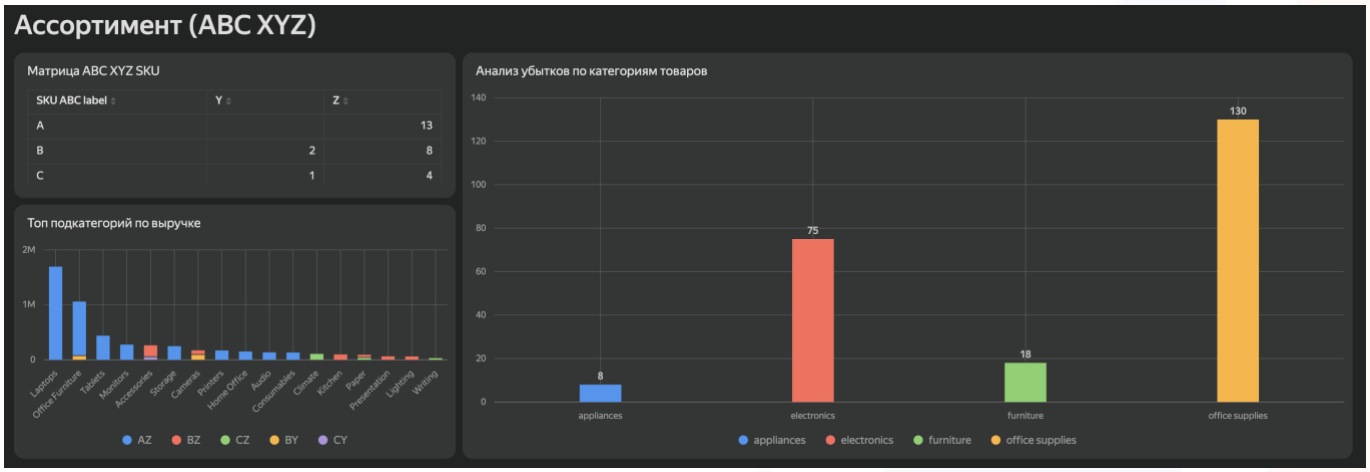
- **Online** — лидер по выручке ($1 907 604, 37%)
- **B2B Portal** — лидер по среднему чеку ($1 001)
- **Phone Order** — наименьший канал ($356 535, 7%)
- Маржа стабильна across каналов: 19,8%–20,4%

Bulk-заказы (20% выручки) имеют ту же маржу 20,1%, что и обычные — значит, крупные заказы не «съедают» прибыльность.



3.4. «Ассортимент» (ABC/XYZ)

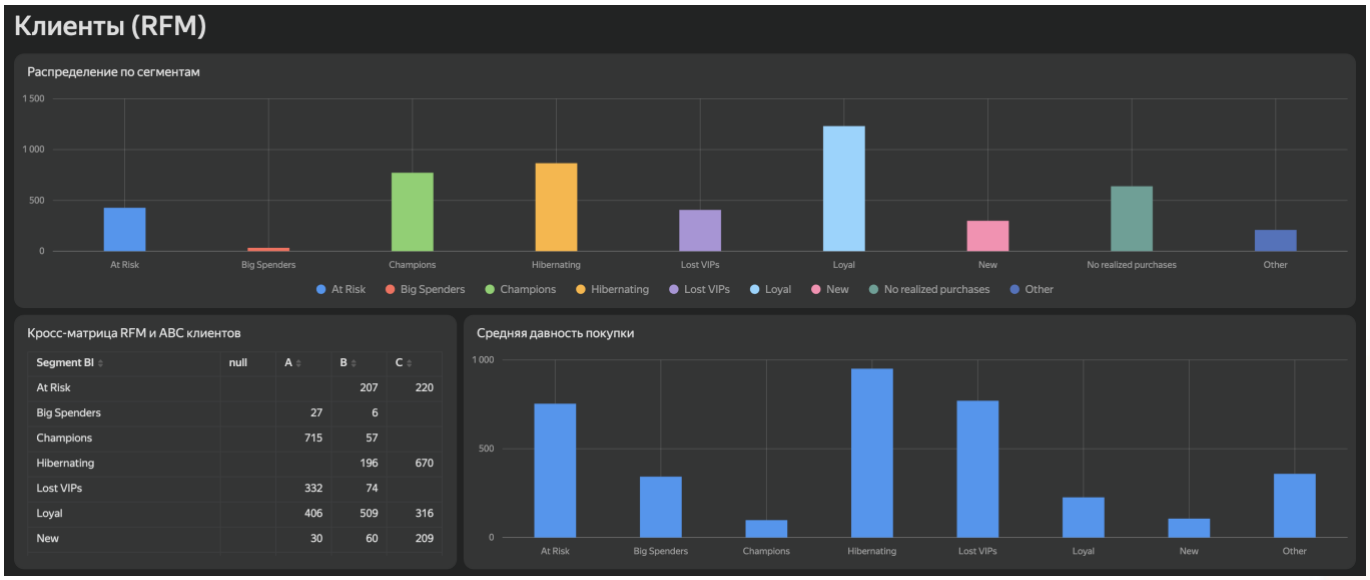
Матрица ABC/XYZ SKU подтверждает инсайт из ноутбука: все 13 «A»-товаров в группе «Z». Анализ убытков показывает, что 56% убыточных транзакций категории `office supplies`.



3.5. Клиенты (RFM)

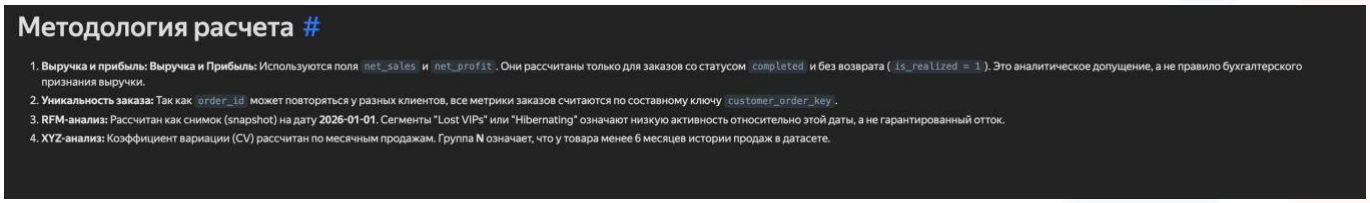
Вкладка показывает распределение 4 882 клиентов по 8 RFM-сегментам и кросс-матрицу RFM × ABC. Ключевые наблюдения:

- **Champions** (772 клиента, 18%) – 44% выручки, средняя давность 97 дней;
- **Loyal** (1 231 клиент, 25%) — 28% выручки;
- **Hibernating** + **At Risk** (1 293 клиента, 27%) – требуют реактивации;
- **Lost VIPs** (406 клиентов) — высокая давность (761 день), но высокий Monetary – приоритет для win-back кампаний.



3.6. Методология

Текстовая вкладка содержит описание методологии расчёта метрик, ограничений и допущений. Это критически важный элемент профессионального дашборда – он защищает от неверных интерпретаций.



ВЫВОДЫ И РЕКОМЕНДАЦИИ

Бизнес-выводы

- Выручка растёт (+17% за 4 года), маржа стабильна (~20%).
- Online — лидер по выручке (37%), B2B Portal — по среднему чеку ($1 001).
- 231 убыточная транзакция office supplies и electronics — требуется аудит ценообразования.
- Все «A»-товары имеют нестабильный спрос (Z) — риск дефицита/излишков, требуется увеличение страхового запаса и еженедельный мониторинг.
- Champions и Loyal = 43% клиентов, но 72% выручки — фокус на удержании.
- Hibernating + At Risk = 27% клиентов с давностью > 700 дней — кандидаты на реактивационные кампании.

Рекомендации

- Для AZ-товаров: увеличить страховой запас, мониторить еженедельно, рассмотреть альтернативных поставщиков.
- Для Hibernating и At Risk: запустить реактивационные email/SMS-кампании с персональными предложениями.
- Для B2B Portal: развивать канал — высокий чек при той же марже, потенциал роста.
- Для Lost VIPs: win-back кампании с эксклюзивными предложениями.
- Аудит убыточных транзакций в office supplies — проверить ценообразование и условия поставок.